

Статистика в OSINT: як працювати з даними та знаходити закономірності

Заняття №17

AI для OSINT і розвідки

Лектор
Василь Попов

r_d

ПЛАН ЗАНЯТТЯ



- Основи та термінологія
- Класифікація статистичних методів в OSINT
- Методологія та інструменти
- Використання та обмеження

ОСНОВНА ЗАДАЧА СТАТИСТИКИ

Оцінити варіативність та зменшити невизначеність

Навіщо використовувати статистику в OSINT?

- Систематизувати дані
- Виявити закономірності
- Оцінити достовірність інформації
- Зробити обґрунтовані висновки.



- Типи даних
- Вибірка
- Діапазон
- Впорядкований ряд даних
- Розподіл

МОДУЛЬ 1

Основи та термінологія



ТИПИ ДАНИХ

Кількісні

- дискретні
- неперервні

Категоріальні

- впорядковані
- неупорядковані

ЩО ТАКЕ ВИБІРКА?

Вибірка — це підмножина елементів із великої сукупності (генеральної сукупності), яку ми аналізуємо, щоб зробити висновки про всю сукупність.

Простими словами: вибірка — це "маленька копія" великої групи, яку ми вивчаємо замість усієї групи.

Основні характеристики вибірки

Параметр	Опис
Розмір вибірки (n)	Кількість об'єктів у вибірці
Репрезентативність	Наскільки добре вибірка відображає генеральну сукупність
Спосіб відбору	Випадкова чи цільова вибірка
Похибка вибірки	Рівень можливої неточності висновків

ТИПИ ВИБІРОК

Грамотно сформована вибірка дозволяє отримати точні висновки про великі сукупності, не аналізуючи їх повністю.

Проста випадкова вибірка:

Кожен елемент має однаковий шанс бути обраним.

Стратифікована вибірка:

Групування за важливими характеристиками перед вибором.

Кластерна вибірка:

Вибір груп (кластерів) об'єктів замість окремих об'єктів.

Впорядкований ряд даних - це набір даних, в якому елементи розташовані у певному порядку, наприклад, за зростанням або спаданням.

Це може бути ряд чисел, ряд слів або будь-який інший тип даних, який можна впорядкувати.

Діапазон - це різниця між найбільшим і найменшим значенням у вибірці.

Він показує розкид даних.



ЩО ТАКЕ РОЗПОДІЛ ДАНИХ

Розподіл — спосіб представлення даних, за допомогою якого можна оцінити як часто зустрічається те, чи інше значення в датасеті.




Він показує:

- Як часто зустрічаються різні значення.
- Які значення типові, а які — рідкісні.
- Чи є в даних закономірності, викиди або аномалії.

ОСНОВНІ ТИПИ РОЗПОДІЛІВ


Нормальний розподіл (дзвоноподібний):

Більшість значень згруповані навколо середнього, симетричні хвости.




Асиметричні розподіли:

Хвіст розподілу витягнутий ліворуч або праворуч (зміщення в один бік).




Багатовершинні розподіли (мультимодальні):


Дані мають кілька піків.




НАВІЩО АНАЛІЗУВАТИ РОЗПОДІЛИ В ДОСЛІДЖЕННЯХ?



Виявляти структурні аномалії
наприклад, групи з підозрілою поведінкою)




Правильно обирати методи подальшого аналізу
(наприклад, чи застосовувати параметричні чи непараметричні тести)




Підвищувати якість прогнозування
та аналітичних моделей


Distribution of property sales: January 2013 to September 2019



Гістограма
(частота різних значень)




Boxplot
(медіана, квартили,
викиди)



Density Plot
(плавна оцінка
розподілу)

ПРИКЛАДИ ВІЗУАЛІЗАЦІЇ РОЗПОДІЛІВ



- Описова статистика
- Інференційна статистика
- Кореляційний аналіз і регресія
- Баєсовий аналіз
- Кластеризація та сегментація

МОДУЛЬ 2

Класифікація статистичних
методів в OSINT




ОПИСОВА СТАТИСТИКА

Середні значення – це сума всіх елементів вибірки, поділена на їхню кількість.

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Мода – це значення, яке найчастіше зустрічається у вибірці даних.



Медіана – це середнє значення у впорядкованому ряду даних. Вона розділяє вибірку навпіл: 50% значень менше або дорівнюють медіані, а 50% – більше

Для непарної кількості спостережень – середній елемент.

Для парної – середнє двох середніх значень.

Коли є багато викидів (наприклад, акаунти-гіганти з мільйонами підписників), медіана краще відображає типовий випадок.

РОЗКИД І ВАРІАТИВНІСТЬ


Діапазон

Приклад: Мінімальний і максимальний вік респондентів.

Дисперсія (Variance) та Стандартне відхилення (Standard Deviation)

Відображають розкид навколо середнього значення і відповідно ширину розподілу

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$




ОПИСОВА АНАЛІТИКА. ПРАКТИЧНИЙ СЕНС

Частоти згадок ключових слів чи подій у соціальних мережах.


Розподіл інформаційних подій у часі (таймсерії), аналіз активності за днями, тижнями.

Виявлення піків активності в інформаційних кампаніях.



ІНФЕРЕНЦІЙНА СТАТИСТИКА

Описова статистика обчислює такі показники, як середнє значення, медіана, мода, дисперсія та стандартне відхилення — але робить це тільки для конкретної вибірки чи сукупності даних, яку ми маємо на руках



Інференційна статистика використовується для того, щоб за допомогою вибірових даних зробити висновки про невідому генеральну сукупність.

І саме тут починається робота з ймовірностями та похибками. Тобто замість "що є в нашій вибірці" ми вже питаємо "яке справжнє значення в усій популяції?"

МЕТОДИ ІНФЕРЕНЦІЙНОЇ СТАТИСТИКИ. ТЕСТУВАННЯ ГІПОТЕЗ

Це метод перевірки припущень про характеристики сукупності на основі вибірових даних.

Приклад: перевірка гіпотези про зростання активності фейкових акаунтів під час виборів.

Основні етапи:

- **Формулювання нульової гіпотези (H_0):**
Це твердження, яке ми перевіряємо і за замовчуванням вважаємо істинним. Зазвичай H_0 каже: "нічого не змінилося", "різниці немає", "ефекту немає".
- **Альтернативна гіпотеза (H_1):**
Це припущення, яке ми хочемо довести. Вона каже: "є різниця", "ефект присутній", "щось змінилося".
- **Обчислюємо p -value** - ймовірність отримати наш результат, **якщо H_0 була б правдою.**
- Ми обираємо **рівень значущості** (найчастіше $\alpha=0.05$) та порівнюємо з **p -value.**


ПОБУДОВА ДОВІРЧИХ ІНТЕРВАЛІВ

вибіркове середнє

стандартне відхилення

критичне значення для заданого рівня довіри

розмір вибірки



$$CI = \bar{x} \pm z \cdot \frac{\sigma}{\sqrt{n}}$$

Рівень довіри	Критичне значення (z)
90%	1.645
95%	1.96
99%	2.576

КОРЕЛЯЦІЙНИЙ АНАЛІЗ

Вимірювання зв'язків між змінними.

Основний показник — коефіцієнт кореляції (r):

- $r = +1$ — ідеальний позитивний зв'язок
- $r = -1$ — ідеальний негативний зв'язок
- $r = 0$ — зв'язку немає



Зв'язок між подіями.

Напр. активність ботів $\leftrightarrow$ виборчі кампанії.

Виявлення залежностей між кількома типами активності (наприклад, кількість постів і кількість репостів).

КОЕФІЦІЄНТ ПІРСОНА

Коефіцієнт Пірсона показує **силу та напрямок лінійного зв'язку** між двома числовими змінними.

Підходить, коли перевіряємо: якщо одна змінна зростає, чи інша зростає пропорційно?

Коли застосовувати:

- Дані числові і мають приблизно нормальний розподіл
- Хочемо знайти саме лінійний зв'язок (пряма лінія на графіку)

$$\text{Cov}(X, Y) = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{n - 1}$$

$$r = \frac{\text{Cov}(X, Y)}{\sigma_X \cdot \sigma_Y}$$

КОЕФІЦІЄНТ СПІРМЕНА

Коефіцієнт Спірмена вимірює силу та напрямок монотонного зв'язку — не обов'язково лінійного.



Коли застосовувати:

- Дані порядкові або з викидами
- Відносини між змінними не обов'язково лінійні, але монотонні (зростають або зменшуються загалом)

Як працює:


- Перетворює дані в ранги
 $[11, 35, 20] \rightarrow [1, 3, 2]$
- Потім рахує зв'язок між рангами

МІНІМАЛЬНИЙ НАБІР ДЛЯ СТАРТУ

- Інструмент: Excel, Google Sheets, Python (pandas), R
- Функція: CORREL() (в Excel) або .corr() (у pandas)
- Візуалізація: діаграма розсіювання (scatter plot)

Важливо пам'ятати:

- Кореляція $\neq$ причинність
- Якщо два показники пов'язані — це ще не значить, що один викликає інший.
- Дані мають бути чистими
- Шумні чи неповні дані можуть спотворити зв'язок.
- Краще використовувати графіки
- Графіки допомагають візуально побачити кореляцію.



strong, positive, linear



moderate, negative, linear




null / no relationship



strong, non-linear

РЕГРЕСІЙНИЙ АНАЛІЗ




Це метод, який дозволяє вивчити залежність між змінними і передбачати одне значення на основі інших.

РЕГРЕСІЙНИЙ АНАЛІЗ. ЛІНІЙНА РЕГРЕСІЯ


Лінійна регресія - для базових прогнозів.


$$Y = a + b \cdot X$$



Алгоритм шукає пряму, яка максимально близька до всіх точок.

Приклад: прогнозування кількості згадок певного об'єкта за наявними даними.






$$L1 = \sum |\text{фактичне значення} - \text{прогнозоване значення}|$$

$$L2 = \sum (\text{фактичне значення} - \text{прогнозоване значення})^2$$



Мінімізація L1



Мінімізація L2

L2 більш чутливі до викидів

РЕГРЕСІЙНИЙ АНАЛІЗ. МНОЖИННА РЕГРЕСІЯ

Характеризує залежність функції Y від декількох величин X .

Проста інтерпретація, працює при нормальних умовах, але не ловить складні залежності.

$$Y = aX_1 + bX_2 + cX_3 + d$$



ЛОГІСТИЧНА РЕГРЕСІЯ

Застосовують у випадку, коли залежна змінна є бінарною, корисна для класифікації

Логістична регресія не передбачає значення — вона передбачає ймовірність. Наприклад: «З імовірністю 82% ця людина купить продукт».

Класичний інструмент для виявлення ризиків чи загроз.

Наприклад: чи є акаунт ботом чи справжньою людиною?



Чи належить профіль до конкретної групи?



Класифікація електронних листів на «спам» або «не спам».



Метод також використовується у медицині, наприклад, для визначення чи є пухлина злоякісною, чи доброякісною.



LASSO/RIDGE (РЕГУЛЯРИЗОВАНІ РЕГРЕСІЇ)

Коли даних дуже багато: Наприклад, ти моніториш 50+ факторів по країні: соцмережі, новини, економіку, дипломатію тощо.

Хочеш автоматично відсіяти несуттєві фактори й залишити головні для прогнозу конфліктів чи криз.


$$Y = aX_1 + bX_2 + cX_3 + d$$



ДЕРЕВА РІШЕНЬ І БУСТИНГ (XGBOOST, LIGHTGBM)

Наприклад, ти будуєш модель, яка прогнозує вторгнення на основі купи сигналів: переміщення військ, риторика в медіа, економічні дані.

Дуже гнучкі, працюють з нелінійними залежностями.



БАЄСОВИЙ АНАЛІЗ (ТЕОРЕМА БАЄСА)

$P(\text{Гіпотеза} \mid \text{Дані})$ — нова ймовірність після врахування даних (апостеріорна)

$P(\text{Дані} \mid \text{Гіпотеза})$ — наскільки ймовірні ці дані за умови, що гіпотеза вірна

$P(\text{Гіпотеза})$ — наша початкова віра (апріорна ймовірність)

$P(\text{Дані})$ — загальна ймовірність даних


$$P(\text{Гіпотеза} \mid \text{Дані}) = \frac{P(\text{Дані} \mid \text{Гіпотеза}) \cdot P(\text{Гіпотеза})}{P(\text{Дані})}$$

ЗАСТОСУВАННЯ ТЕОРЕМИ


Ймовірнісне оновлення знань при надходженні нової інформації.

Оновлення початкових припущень у світлі нової інформації.

Приклад: оцінка ймовірності фейковості акаунта після аналізу патернів поведінки.




Баєсівське оновлення при несиметричних даних



ТЕРМІНОЛОГІЯ ОЦІНКИ ЙМОВІРНОСТІ



PROBABILITY YARDSTICK




КЛАСТЕРИЗАЦІЯ ТА СЕГМЕНТАЦІЯ


Виявлення груп акаунтів з подібною поведінкою (напр., ботоферми).

Групування акаунтів, статей, профілів за схожими характеристиками.


Приклад: виявлення ботоферм або автоматичних мереж поширення контенту.




ПРИКЛАДИ МЕТОДІВ КЛАСТЕРИЗАЦІЇ



K-means — поділяє об'єкти на K груп, мінімізуючи відстань усередині групи. Добре працює на числових даних (наприклад, по доходу і віку).






DBSCAN — шукає щільні скупчення об'єктів і ігнорує "шумні" або розріджені дані. Підходить для виявлення аномалій.




Louvain / Leiden — спеціалізовані методи для графів (мереж), знаходять спільноти за структурою зв'язків.

ПРИКЛАД K-MEANS




ПРИКЛАД DBSCAN




ПОРІВНЯННЯ К-MEANS ТА DBSCAN

DBSCAN



k-means



ПРИКЛАД LOUVAIN/LEIDEN

Кластеризація на основі зв'язків



СЕГМЕНТАЦІЯ

Сегментація — це усвідомлений поділ на частини

Тут людина задає принципи поділу, а система вже виконує це.



Приклади підходів:

1. Сегментація аудиторії за регіоном, віком, доходом (тобто за заданими категоріями).
2. Сегментація мережі на основі заздалегідь відомих груп (наприклад, ми знаємо підрозділи в організації і ділимо співробітників за цим принципом).
3. В OSINT: наприклад, розділити акаунти соцмереж за мовою, країною чи поведінкою.

- Інтеграція в розвідувальний цикл
- Трамбування результатів
- Джерела даних
- Приклади інструментів

МОДУЛЬ 3

Методологія
та інструменти



ЦИКЛ РОЗВІДКИ + СТАТИСТИЧНИЙ ФРЕЙМВОРК


Крок 1: Запишіть свої гіпотези та сплануйте дизайн дослідження

Крок 2: Зберіть дані з вибірки

Крок 3: Узагальніть свої дані за допомогою описової статистики

Крок 4: Перевірте гіпотези або зробіть оцінки за допомогою інференційної статистики

Крок 5: Інтерпретуйте свої результати




ТРАКТУВАННЯ РЕЗУЛЬТАТІВ. ЙМОВІРНІСТЬ ≠ 100% ВПЕВНЕНІСТЬ

Статистика завжди дає результати з певною невизначеністю:

- Наприклад, якщо у тебе p -значення = 0.03, це не означає, що гіпотеза хибна з ймовірністю 97%.
- Це означає: "Якщо нульова гіпотеза правильна, ми очікували б побачити такі дані лише в 3% випадків".


Як вирішувати: завжди підкреслювати діапазон невизначеності (довірчі інтервали, байєсові розподіли).



СТАТИСТИЧНА ЗНАЧУЩІСТЬ $\neq$ ПРАКТИЧНА ВАЖЛИВІСТЬ

- Ти можеш знайти статистично значущий ефект (наприклад, різницю середнього зросту на 1 см), але з практичної точки зору це дрібниця.
- І навпаки — важливий ефект може бути незначущим, якщо у тебе маленька вибірка.

Як вирішувати: завжди поряд з p-value наводити розмір ефекту (наприклад, різниця в см, коефіцієнт, відсоток) і пояснювати його контекстуальну значущість.




КОРЕЛЯЦІЯ $\neq$ ПРИЧИННІСТЬ

- Якщо два показники пов'язані, це не означає, що один викликає інший.
- Часто зв'язок обумовлений третьою змінною.

Проблема: люди інтуїтивно шукають причинно-наслідкові зв'язки там, де їх немає.


Як вирішувати: підкреслювати, що аналіз кореляцій описує зв'язки, а не причини. Для причинності потрібні експерименти або складніші моделі (наприклад, інструментальні змінні, структурні моделі).



ВИБІРКОВІ ДАНІ = СПОТВОРЕНІ ВИСНОВКИ

- Якщо дані зібрані не репрезентативно (наприклад, тільки з міста, тільки з молоді тощо), результати не можна узагальнити на всю популяцію.


Як вирішувати: чітко вказувати обсяг і склад вибірки, обмеження дослідження.



МНОЖИННЕ ТЕСТУВАННЯ = ЗРОСТАННЯ ПОМИЛОК

- Якщо ти тестуєш багато гіпотез одночасно (наприклад, 100 ознак), завжди знайдеш кілька "значущих" просто випадково.

Як вирішувати: застосовувати корекції (наприклад, метод Бонферроні, FDR), або байєсові методи.



ДОДАТКОВІ ТИПОВІ ПРОБЛЕМИ

Проблема	Рішення
Погане трактування довірчих інтервалів	Пояснювати їх як діапазон, де лежить істинне значення з певною імовірністю
Оверфітинг моделей — це коли твоя модель занадто добре підлаштовується під конкретні дані, але через це погано працює на нових, ще не бачених прикладах	Використовувати валідацію, крос-валідацію
Ігнорування відсутніх даних	Чітко описувати, як оброблялись пропуски
Суб'єктивні висновки з малих вибірок	Вказувати розмір вибірки та обмеження потужності тесту

ТРАКТУВАННЯ РЕЗУЛЬТАТІВ АНАЛІТИЧНОГО ДОСЛІДЖЕННЯ

Завжди наводити не лише p -value, а й розмір ефекту

Використовувати довірчі інтервали чи баєсові діапазони для показу невизначеності

Уникати категоричних висновків типу "ми довели" — краще "результати свідчать на користь..."

Вказувати обмеження вибірки та потенційні джерела спотворень

Якщо це кореляція — явно вказувати, що це не обов'язково причинний зв'язок

У складних аналізах перевіряти стабільність результатів на інших підвибірках (робастність)

ДЖЕРЕЛА ДАНИХ В OSINT

Структуровані (таблиці, CSV, API)

- Таблиці, БД, JSON-файли, CSV-файли.
- Приклад: база WHOIS-реєстрацій доменів.

Неструктуровані (тексти, відео, зображення)

Приклад: коментарі на форумах або статті в медіа

ПРИКЛАДИ ІНСТРУМЕНТІВ

Інструмент	Особливості
Excel / Google Sheets	Ідеально для базових обчислень, середніх, дисперсій, кореляцій. Має вбудовані функції типу CORREL, T.TEST і навіть регресії.
SPSS	Комерційний інструмент від IBM
Jamovi	Безкоштовна альтернатива SPSS з графічним інтерфейсом. Все кліками, не треба програмувати. Підходить для t-тестів, ANOVA, регресій.
JASP	Також безкоштовний, має багато фіч
Stata	Повне статистичне програмне забезпечення для обробки даних
Minitab	Комерційний інструмент. Комбайн.
Apache Spark (MLlib)	Багатомовний механізм для виконання інженерії даних, науки про дані та машинного навчання на одновузлових машинах або кластерах.

- Машинне навчання з використанням статистичних моделей
- Стек технологій
- Приклади використання
- Обмеження статистичних методів в OSINT

МОДУЛЬ 4


Використання та
обмеження



МАШИННЕ НАВЧАННЯ З ВИКОРИСТАННЯМ СТАТИСТИЧНИХ МОДЕЛЕЙ

Що таке статистичні моделі в ML для OSINT?

Статистичні моделі — це моделі, які описують ймовірності або розподіли даних.



У машинному навчанні вони використовуються для:

- класифікації об'єктів, наприклад, акаунтів як фейкових або реальних
- виявлення аномалій, наприклад, незвичної активності в соцмережах
- прогнозування, наприклад, ймовірності появи інформаційної атаки або витоку даних

ОСНОВНІ СТАТИСТИЧНІ МОДЕЛІ, ЩО ЗАСТОСОВУЮТЬСЯ В OSINT

Модель	Що робить	Приклади використання
Наївний баєсівський класифікатор (Naive Bayes)	Оцінює ймовірність належності об'єкта до певного класу	Класифікація новин: правда чи фейк
Логістична регресія	Обчислює ймовірність двійкової події	Чи є акаунт ботофермою
Лінійна регресія	Прогнозує числові значення	Прогноз інтенсивності кампанії дезінформації
Кластеризація (наприклад, K-means)	Групує схожі об'єкти без міток	Групування Telegram-каналів за тематикою

МОДЕЛІ ЧАСОВИХ РЯДІВ (ARIMA, ETS)

Це моделі, які працюють з даними, що змінюються з часом

ARIMA

Модель, яка враховує минулі значення та їх зміни

ETS

Модель, яка базується на тренді, сезонності і помилці

E — помилка (Error): непередбачувана частина

T — тренд (Trend): чи дані зростають або знижуються

S — сезонність (Seasonality): регулярні повторення (наприклад, щотижня або щороку)

КЕЙС 1-1 ЗАСТОСУВАННЯ МОДЕЛЕЙ НА ПРАКТИЦІ. ВИБОРИ В США (2016–2020)

01

Ціль — виявити бот-мережі, які координовано поширювали дезінформацію.

02

Застосовували логістичну регресію — щоб класифікувати акаунти як боти чи ні, базуючись на частоті твітів, підписниках і т.д.

03

Потім кластеризація (K-means) — групувала акаунти з подібними ознаками, виявляючи бот-мережі

04

Результат: десятки тисяч ботів було виявлено, вони впливали на політичний дискурс.

КЕЙС 1-2 ВИЯВЛЕННЯ БОТ-МЕРЕЖ У TWITTER ПІД ЧАС ВИБОРІВ У США (2016–2020)

Ціль:

виявити скоординовану кампанію дезінформації з використанням ботів.

Методи:

- Логістична регресія: використовувалась для класифікації акаунтів як ботів або реальних користувачів, на основі ознак: частота твітів, структура підписників, мова постів.
- Кластеризація (K-means): для групування акаунтів за схожими ознаками
- — виявлено бот-мережі, які просували однакові меседжі.

Результат:

виявлено десятки тисяч ботів, які впливали на інформаційний простір у період перед виборами.

КЕЙС 2-1 COVID-19 І ФЕЙКИ

01

Ціль — автоматично розпізнати фейкові новини

02

Застосовували наївний баєсівський класифікатор — аналіз текстів, ключових слів, заголовків.

03

Також використовували TF-IDF + логістичну регресію — щоб виявити, які слова типові для фейків.

04

Результат: автоматично виявили десятки тисяч фейкових постів у соцмережах.

КЕЙС 2-2 ВИЯВЛЕННЯ ДЕЗІНФОРМАЦІЇ ПІД ЧАС COVID-19

Ціль:

автоматично
класифікувати новини
як фейкові або
правдиві.

Методи:



- Наївний баєсівський класифікатор: аналізував текст новин (заголовки, ключові слова) й оцінював імовірність того, що новина є дезінформацією.
- TF-IDF + логістична регресія: аналізували, які терміни частіше зустрічаються у фейкових статтях, наприклад: «вакцини вбивають», «5G передає вірус» і т.д.

Результат:

автоматично
відфільтровано десятки
тисяч фейкових новин у
Facebook/YouTube/Twitter.

КЕЙС 3-1


ВІЯВЛЕННЯ ДЕЗІНФОРМАЦІЇ У TWITTER. АНАЛІЗ ПОШИРЕННЯ ТВІТІВ, ХЕШТЕГІВ, ЧАСТОТИ ПУБЛІКАЦІЙ



КЕЙС 3-2

РОЗПОДІЛ ОСНОВНИХ ТЕМ SECONDARY INFECTION ЗА МОВАМИ, ЯКИМИ ВОНИ БУЛИ ОПУБЛІКОВАНІ

Themes by Language



КЕЙС 3-3


ВТОРИННА ІНФЕКЦІЯ: ОСНОВНІ ТЕМИ З ПЛИНОМ ЧАСУ

Articles by Theme over Time

	Grand Total	2014				2015				2016				2017				2018				2019				2020
		Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1	Q2	Q3	Q4	Q1
Failed / unreliable Ukraine	830	3	1	6	48	39	139	70	30	86	34	15	14	25	18	26	9	7	47	48	69	7	55	8	15	11
US / NATO aggression	536	3	2	2	6	4	34	38	11	19	28	37	19	43	20	31	30	24	45	33	4	65	6	5	24	3
Divides / Weaknesses in Europe	508	1		5	7	3	38	16	27	10	10	13	76	18	27	23	6	25		60	98		29		16	
Insulting Kremlin critics	214	5	1			2	4			19	45	9	4	4	27	17	1	4	2	19	17	1		6	27	
Migration and Muslims	173				1		3	7	16	37	33		6			10	5				1		20	1	19	14
Defending Russia / Putin	158	4		1		5	10	7	9	2	15	7	1	13		18		3	12		32	1		18		
Other	118		1	6	3	7	23	6	11	6	13	1		7					2	32						
Election Focus	110								3	3	23	20	12	16						11	22					
Turkish Aggression	81								27	20	23				5			1		5						
Sports / doping	29										5	2					18	4								


КЕЙС 3-4

мережева карта GRAPHІКА
підписників активів
secondary infection у
twitter
та підписників
значних підсилювачів,
станом на квітень
2020 року.




КЕЙС 4-1:


КУБИНСЬКА РАКЕТНА КРИЗА – РОЗВІДУВАЛЬНІ ЗНІМКИ ТА АНАЛІЗ РОЗВІДУВАЛЬНИХ ДАНИХ U-2



Розвідувальні знімки U-2: Висотні літаки-розвідники U-2 зробили детальні фотографії ракетних установок на Кубі.



Розвідка радіосигналів (SIGINT): Перехоплені повідомлення дали уявлення про військову діяльність СРСР.



Розвідка людей (HUMINT): Інформація з таких джерел, як Олег Пеньковський, офіцер радянської військової розвідки, який надав важливі подробиці про радянські ракетні можливості.

КЕЙС 4-2 МЕТОДИ КІЛЬКІСНОГО АНАЛІЗУ

Аналіз зображень

Аналітики Національного центру інтерпретації фотографій (NPIC) ретельно вивчили фотографії U-2, щоб ідентифікувати місця розташування ракет. Вони вимірювали розміри об'єктів, оцінювали схеми будівництва та порівнювали їх з відомими радянськими ракетними установками.

Баєсівський висновок

Хоча на той час це не було чітко позначено як таке, розвідувальне співтовариство використовувало міркування, подібні до баєсівського. Початкові переконання (апріорні) щодо радянських намірів оновлювалися, оскільки нові докази (ймовірність) з'являлися на знімках U-2 та інших джерел, що призводило до перегляду оцінок (апостеріорних) щодо рівня загрози.

КЕЙС 5-1 ПРОВАЛ РОЗВІДКИ

Незважаючи на остаточне виявлення ракет, деякі вчені стверджують, що криза є провалом розвідки. Радянському Союзу вдалося перевезти та розпочати встановлення ядерних ракет на Кубі, залишаючись непоміченими протягом кількох тижнів.

Ця затримка, відома як «фотопрогалина», була частково пов'язана з погодними умовами та тимчасовим призупиненням польотів U-2 над Кубою.

Нездатність виявити ракети раніше дозволила Радянському Союзу встановити значну військову присутність у Західній півкулі, перш ніж США змогли відреагувати.



СТЕК ТЕХНОЛОГІЙ

Data science and Machine learning




SQL analytics and BI



Storage and Infrastructure



ПРОГРАМУВАННЯ НА R



```
# Load libraries
library(caret)

# Sample dataset
data <- data.frame(
  num_tweets = c(100, 10000, 50, 5000, 30, 20000, 15, 15000),
  num_followers = c(10, 100, 5, 3000, 12, 10000, 3, 8000),
  account_age_days = c(200, 30, 300, 45, 365, 20, 500, 25),
  is_bot = factor(c(0, 1, 0, 1, 0, 1, 0, 1)) # Factor for classification
)

# Split into training and test sets
set.seed(42)
trainIndex <- createDataPartition(data$is_bot, p = .7, list = FALSE)
train <- data[trainIndex, ]
test <- data[-trainIndex, ]

# Train logistic regression model
model <- glm(is_bot ~ num_tweets + num_followers + account_age_days,
  data = train, family = binomial)

# Predict on test data
pred_probs <- predict(model, newdata = test, type = "response")
pred_class <- ifelse(pred_probs > 0.5, 1, 0)

# Evaluation
conf_matrix <- confusionMatrix(factor(pred_class), test$is_bot)
print(conf_matrix)

# Predict on new account
new_account <- data.frame(num_tweets = 12000,
  num_followers = 100,
  account_age_days = 15)
new_pred <- predict(model, new_account, type = "response")
cat("Prediction for new account (1=bot, 0=human):", ifelse(new_pred > 0.5, 1, 0), "\n")
```

ПРОГРАМУВАННЯ НА PYTHON

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, confusion_matrix
```

```
# Sample dataset
```

```
data = {
    "num_tweets": [100, 10_000, 50, 5000, 30, 20_000, 15, 15000],
    "num_followers": [10, 100, 5, 3000, 12, 10_000, 3, 8000],
    "account_age_days": [200, 30, 300, 45, 365, 20, 500, 25],
    "is_bot": [0, 1, 0, 1, 0, 1, 0, 1]
}
```

```
df = pd.DataFrame(data)
```

```
# Features and target
```

```
X = df[["num_tweets", "num_followers", "account_age_days"]]
y = df["is_bot"]
```

```
# Split dataset
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
```

```
# Create and train model
```

```
model = LogisticRegression()
model.fit(X_train, y_train)
```

```
# Predict and evaluate
```

```
y_pred = model.predict(X_test)
```

```
print("Confusion Matrix:")
```

```
print(confusion_matrix(y_test, y_pred))
```

```
print("\nClassification Report:")
```

```
print(classification_report(y_test, y_pred))
```

```
# Predict on new data
```

```
new_account = pd.DataFrame([
    "num_tweets": 12000,
    "num_followers": 100,
    "account_age_days": 15
])
```

```
prediction = model.predict(new_account)
```

```
print("\nPrediction for new account (1=bot, 0=human):", prediction[0])
```

ОБМЕЖЕННЯ СТАТИСТИЧНИХ МЕТОДІВ В OSINT

Проблеми з достовірністю даних

Семплінгова похибка: невелика або нерепрезентативна вибірка може призвести до неправильних висновків.

Неоднозначність тлумачення

Інтерпретаційні ризики: кореляція не означає причинно-наслідковий зв'язок.

Вплив людського фактора та етичні аспекти

Етичні та правові обмеження: важливо враховувати конфіденційність, права людини.

Якість даних: відкриті джерела можуть містити неточності, фальсифікації або бути неповними.

ВИСНОВКИ

01

Статистика $\neq$ відповідь, але вона допомагає ставити правильні запитання

02

Статистичні методи — потужний інструмент у руках аналітика

03

Перспективи розвитку: поєднання з AI/ML для автоматизації аналізу

04

Приклади продуктів

Q&A

???



ЗАВЖДИ Є КУДИ
ЗРОСТАТИ